

Машинное обучение

Лекция 4. Задача классификации, логистическая регрессия

Автор: Рустам Азимов

Санкт-Петербург, 2023г.

Задача предсказания

- ▶ Предсказание значения количественного признака Y называется **задачей регрессии**
- ▶ Предсказание значения номинального (категориального) признака Y называется **задачей классификации**
- ▶ Например, предсказание признака Возраст — это задача регрессии, а предсказание признака Пол — задача классификации

Задача бинарной классификации


- ▶ X — признаки, вещественные числа
- ▶ Целевой признак $Y \in \{-1, +1\}$
- ▶ Линейная модель для классификации:

$$\alpha(x) = \text{sign}\left(\sum_{i=0}^m w_i x_i\right) = \text{sign}\langle w, x \rangle$$


- ▶ Разделяет пространство на две части гиперплоскостью
- ▶ Величина скалярного произведения описывает расстояние до гиперплоскости, а его знак — по какую сторону данный объект

Regression vs Classification

Regression



Classification



Accuracy

- ▶ Если мы хотим угадать все классы в обучающей выборке, то мы легко можем переобучиться
- ▶ Будем считать **accuracy** — долю правильных ответов модели на обучающей выборке с векторами признаков \vec{x}_i и соответствующими им ответами y_i :

$$\frac{1}{n} \sum_{i=1}^n [\alpha(\vec{x}_i) = y_i]$$

- ▶ Для функции ошибок модели α , которую будем минимизировать подходит доля неправильных ответов:

$$Q(\alpha, X) = \frac{1}{n} \sum_{i=1}^n [\alpha(\vec{x}_i) \neq y_i] = \frac{1}{n} \sum_{i=1}^n [\text{sign}\langle w, \vec{x}_i \rangle \neq y_i]$$

- ▶ Так как эта функция дискретна относительно весов w , то градиентный спуск для решения не подходит
- ▶ Может быть много глобальных минимумов

- ▶ Знак характеристики **отступ (margin)** говорит о корректности ответа классификатора:

$$M_i = y_i \langle w, \vec{x}_i \rangle$$

- ▶ Положительный знак — ответ правильный, отрицательный — неправильный
- ▶ А само значение отступа характеризует уверенность нашего классификатора в своём ответе
- ▶ Чем больше значение — тем больше уверенность

- ▶ Тогда функцию ошибки можно переписать в виде:

$$Q(\alpha, X) = \frac{1}{n} \sum_{i=1}^n [\alpha(\vec{x}_i) \neq y_i] = \frac{1}{n} \sum_{i=1}^n [\text{sign}\langle w, \vec{x}_i \rangle \neq y_i] = \frac{1}{n} \sum_{i=1}^n [M_i < 0]$$

- ▶ При значениях M_i близким к нулю, данный объект находится близко к гиперплоскости нашего классификатора, из-за чего у модели низкая уверенность в ответе


Функция потерь бинарного классификатора

- ▶ Вместо того чтобы работать с кусочно-линейной функцией $L(M) = [M < 0]$ можно заменить её на гладкую верхнюю оценку этой функции $\bar{L}(M) \geq L(M)$
- ▶ Например, может быть использована сигмоида: **логистическая функция потерь**

$$\bar{L}(M) = \log(1 + e^{-M})$$

- ▶ Увидим, что такая функция подходит для обучения линейного классификатора

Logistic Function



Оценка качества бинарного классификатора

- ▶ После обучения модели необходимо оценить её качество
- ▶ Рассмотрим более общий вид нашего классификатора:

$$\alpha(x) = [b(x) > t]$$

- ▶ В случае линейной модели $b(x) = \langle w, x \rangle$ и $t = 0$

Оценка качества бинарного классификатора

- ▶ Как уже говорилось, очевидной функцией является доля правильных ответов модели:

$$accuracy(\alpha, x) = \frac{1}{n} \sum_{i=1}^n [\alpha(\vec{x}_i) = y_i]$$

- ▶ Чем плоха оценка *accuracy*?

Оценка качества бинарного классификатора

- ▶ Как уже говорилось, очевидной функцией является доля правильных ответов модели:

$$accuracy(\alpha, x) = \frac{1}{n} \sum_{i=1}^n [\alpha(\vec{x}_i) = y_i]$$

- ▶ Чем плоха оценка *accuracy*?
- ▶ Допустим мы взяли порог t меньше минимального значения прогноза $b(x)$ на обучающей выборке или больше максимального
- ▶ Тогда доля правильных ответов будет равна доле положительных и отрицательных ответов соответственно
- ▶ Если в выборке 990 отрицательных и 10 положительных объектов, то $accuracy(\alpha, x) = 0,99$, хотя предсказатель глупый

Оценка качества бинарного классификатора

- ▶ Поэтому полезно также анализировать соотношение классов в обучающей выборке
- ▶ Вычисляют **базовую долю** — долю правильных ответов модели, которая всегда предсказывает наиболее мощный класс

- ▶ Чтобы оценка была более информативной, рассмотрим следующие критерии

	$y = 1$	$y = -1$
$\alpha(x) = 1$	True Positive (TP)	False Positive (FP)
$\alpha(x) = -1$	False Negative (FN)	True Negative (TN)

- ▶ Тогда доля правильных ответов выражается:

$$accuracy = \frac{TP + TN}{TP + FP + FN + TN}$$

- ▶ Но более информативными являются **точность (precision)** и **полнота (recall)**

$$precision = \frac{TP}{TP + FP}$$

$$recall = \frac{TP}{TP + FN}$$

- ▶ Точность показывает, какая доля объектов, которые по мнению классификатора являются положительными, действительно положительны
- ▶ Полнота показывает, какая доля из положительных объектов была угадана классификатором
- ▶ Можно регулировать точность и полноту, изменяя порог t в классификаторе $\alpha(x) = [b(x) > t]$
- ▶ Если выбрать большое t , то классификатор будет относить к положительному классу небольшое число объектов и, следовательно, точность будет высокой, а полнота — низкой
- ▶ При уменьшении t точность будет падать, а полнота — увеличиваться
- ▶ Конкретное значение порога выбирается согласно пожеланиям заказчика

Пример

- ▶ Задача — предсказать реакцию клиента оператора сотовой связи на звонок с предложением подключить новую услугу
- ▶ Положительные объекты (клиенты) с $y = 1$ это те, кто примут предложение после рекламного звонка
- ▶ Отрицательные с $y = -1$ это те, кто не примут
- ▶ Пытаемся предсказать с помощью классификатора кто примет предложение, а кто нет и будем звонить тем, для кого $\alpha(x) = 1$
- ▶ Важнее точность или полнота?

Пример

- ▶ Задача — предсказать реакцию клиента оператора сотовой связи на звонок с предложением подключить новую услугу
- ▶ Положительные объекты (клиенты) с $y = 1$ это те, кто примут предложение после рекламного звонка
- ▶ Отрицательные с $y = -1$ это те, кто не примут
- ▶ Пытаемся предсказать с помощью классификатора кто примет предложение, а кто нет и будем звонить тем, для кого $\alpha(x) = 1$
- ▶ Важнее точность или полнота?
- ▶ При высокой точности обученного классификатора практически каждый звонок будет результативным для оператора сотовой связи
- ▶ А при высокой полноте — звонки покроют практически всех целевых клиентов

- ▶ Точность и полнота не зависят от соотношения размеров классов в обучающей выборке, но с приходится оперировать двумя критериями
- ▶ Вместо этого можно использовать один критерий, например, **F-меру** — гармоническую среднюю точности и полноты:

$$F = \frac{2 * precision * recall}{precision + recall}$$

- ▶ Гармоническое среднее близко к нулю, если хотя бы один из аргументов близок к нулю
- ▶ F-мера является сглаженной версией минимума из точности и полноты

- ▶ Мы рассмотрели как оценивать классификатор $\alpha(x) = [b(x) > t]$ при известной функции $b(x)$ и выбранном пороге t
- ▶ Но зачастую, порог будет выбираться позже в зависимости от требований к точности и полноте
- ▶ Поэтому мы хотим оценивать качество сразу семейства моделей

$$\{\alpha(x) = [b(x) > t \mid t \in \mathbb{R}]\}$$


- ▶ Широко используется такая интегральная метрика качества семейства, как площадь под **ROC-кривой (Area Under ROC Curve, AUC-ROC)**
- ▶ Чтобы изобразить эту кривую нам нужны FPR и TPR
- ▶ Доля неверно принятых объектов (**False Positive Rate, FPR**)

$$FPR = \frac{FP}{FP + TN}$$

- ▶ И доля верно принятых объектов (**True Positive Rate, TPR**)

$$TPR = \frac{TP}{TP + FN}$$

AUC-ROC



- ▶ Каждый возможный выбор порога t соответствует точке в этом пространстве
- ▶ Всего различных порогов $n + 1$, отсортируем объекты \vec{x}_i по возрастанию функции $b(x)$
- ▶ Максимальный порог $t_{max} = \max_i b(\vec{x}_i)$ даст классификатор с $TPR = 0$ и $FPR = 0$
- ▶ Минимальный порог $t_{min} = \min_i b(\vec{x}_i) - \varepsilon$ даст классификатор с $TPR = 1$ и $FPR = 1$
- ▶ **ROC-кривая** — это кривая с концами в точках $(0, 0)$ и $(1, 1)$, которая последовательно соединяет точки, соответствующие порогам $b(\vec{x}_1) - \varepsilon, b(\vec{x}_1), b(\vec{x}_2), \dots, b(\vec{x}_n)$

Значение AUC-ROC

- ▶ Площадь под этой кривой называется **AUC-ROC** и принимает значения от 0 до 1 и чем больше, тем качественней классификатор
- ▶ При близости площади к 0.5 классификатор ранжирует объекты случайным образом
- ▶ Если площадь меньше 0.5, то предсказывать наоборот выгоднее

- ▶ Метод обучения, который получается при использовании логистической функции потерь, называется **логистической регрессией**

$$\bar{L}(y, \langle w, x \rangle) = \log(1 + e^{-y\langle w, x \rangle})$$

- ▶ Он позволяет корректно оценивает вероятность принадлежности объекта к каждому из классов, например, $p(y = +1 \mid x)$
- ▶ Далее покажем как можно вывести эту функцию ошибок с помощью метода максимального правдоподобия

Максимальное правдоподобие

- ▶ Мы хотим построить $b(x)$ предсказывающую вероятность принадлежности объекта к положительному классу, то есть пусть $b(x)$ имеет область значений $[0, 1]$
- ▶ Наша задача выбрать такую функцию $b(x)$, что правдоподобие выборки (т.е. вероятность получить такую выборку с точки зрения функции $b(x)$) будет максимальным

$$P(\alpha, X) = \prod_{i=1}^n b(\vec{x}_i)^{[y_i=+1]} (1 - b(\vec{x}_i))^{[y_i=-1]} \rightarrow \max$$

- ▶ А точнее удобней перейти к минимизации и к логарифму (чтобы оптимизировать сумму, а не произведение)

$$- \sum_{i=1}^n ([y_i = +1] \log(b(\vec{x}_i)) + [y_i = -1] \log(1 - b(\vec{x}_i))) \rightarrow \min$$

- ▶ Получившаяся функция ошибки или потерь называется **логарифмической (log-loss)**
- ▶ Её можно использовать для обучения
- ▶ Оптимальный ответ равен вероятности положительного класса

Сигмоидная функция

- ▶ Мы требовали, чтобы $b(x)$ имела область значений $[0, 1]$
- ▶ Но для линейного классификатора у нас $b(x) = \langle w, x \rangle$
- ▶ Применяем любую монотонно неубывающую функцию с областью значений $[0, 1]$
- ▶ Мы будем использовать сигмоидную (логистическую) функцию:

$$\sigma(\langle w, x \rangle) = \frac{1}{1 + e^{-\langle w, x \rangle}}$$

- ▶ Таким образом,

$$p(y = +1 \mid x) = \frac{1}{1 + e^{-\langle w, x \rangle}}$$

- ▶ Выразим скалярное произведение

$$\langle w, x \rangle = \log \frac{p(y = +1 | x)}{p(y = -1 | x)}$$

- ▶ Оно равно логарифму отношения вероятностей классов (**log-odds**)

Вывод функции потерь

- ▶ Подставим сигмоидную функцию в функцию потерь для правдоподобия

$$\begin{aligned} & - \sum_{i=1}^n ([y_i = +1] \log \frac{1}{1 + e^{-\langle w, \vec{x}_i \rangle}} + [y_i = -1] \log \frac{e^{-\langle w, \vec{x}_i \rangle}}{1 + e^{-\langle w, \vec{x}_i \rangle}}) \\ &= - \sum_{i=1}^n ([y_i = +1] \log \frac{1}{1 + e^{-\langle w, \vec{x}_i \rangle}} + [y_i = -1] \log \frac{1}{1 + e^{\langle w, \vec{x}_i \rangle}}) \\ &= \sum_{i=1}^n \log(1 + e^{-y_i \langle w, \vec{x}_i \rangle}) \end{aligned}$$

- ▶ Полученная функция в точности представляет собой логистические потери
- ▶ Линейная модель классификации, настроенная путём минимизации данного функционала, называется **логистической регрессией**
- ▶ Она оптимизирует правдоподобие выборки и даёт корректные оценки вероятности принадлежности к положительному классу

Многоклассовая классификация

- ▶ X — признаки, вещественные числа
- ▶ Целевой признак $Y \in \{1, \dots, k\}$, k — количество классов
- ▶ Есть много способов свести к серии бинарных задач оценки вероятности принадлежности к положительному классу

- ▶ **Один против всех (one-versus-all):** обучим k линейных классификаторов $b_1(x), \dots, b_k(x)$, выдающих оценки принадлежности классам $1, \dots, k$ соответственно
- ▶ Классификатор с номером j будем обучать по выборке $(x_i, 2 * [y_i = j] - 1)_{i=1}^n$
- ▶ То есть мы учим классификатор отличать j -ый класс от всех остальных
- ▶ Итоговый классификатор будет выдавать класс, соответствующий самому уверенному из бинарных алгоритмов, то есть с наибольшим $b_j(x)$

- ▶ machinelearning.ru
- ▶ scikit-learn.org
- ▶ [kaggle](https://www.kaggle.com)